

Gemini Notebook









Gemini Notebook


福祸相依。
2021年底，幻方业绩大幅回撤。然而，前期对 AI 算力的重金投入，让其在 2023 年 OpenAI 引发的大模型浪潮中，意外拥有了入局的本钱。
AGI
2023年5月：宣布进军 AGI。
2023年7月：创立“深度求索(DeepSeek)”。
“我们其实并不是故意要成为鲶鱼的，我们只是意外地成为了鲶鱼。”

技术武库（一）降本绝招：MoE 混合专家模型



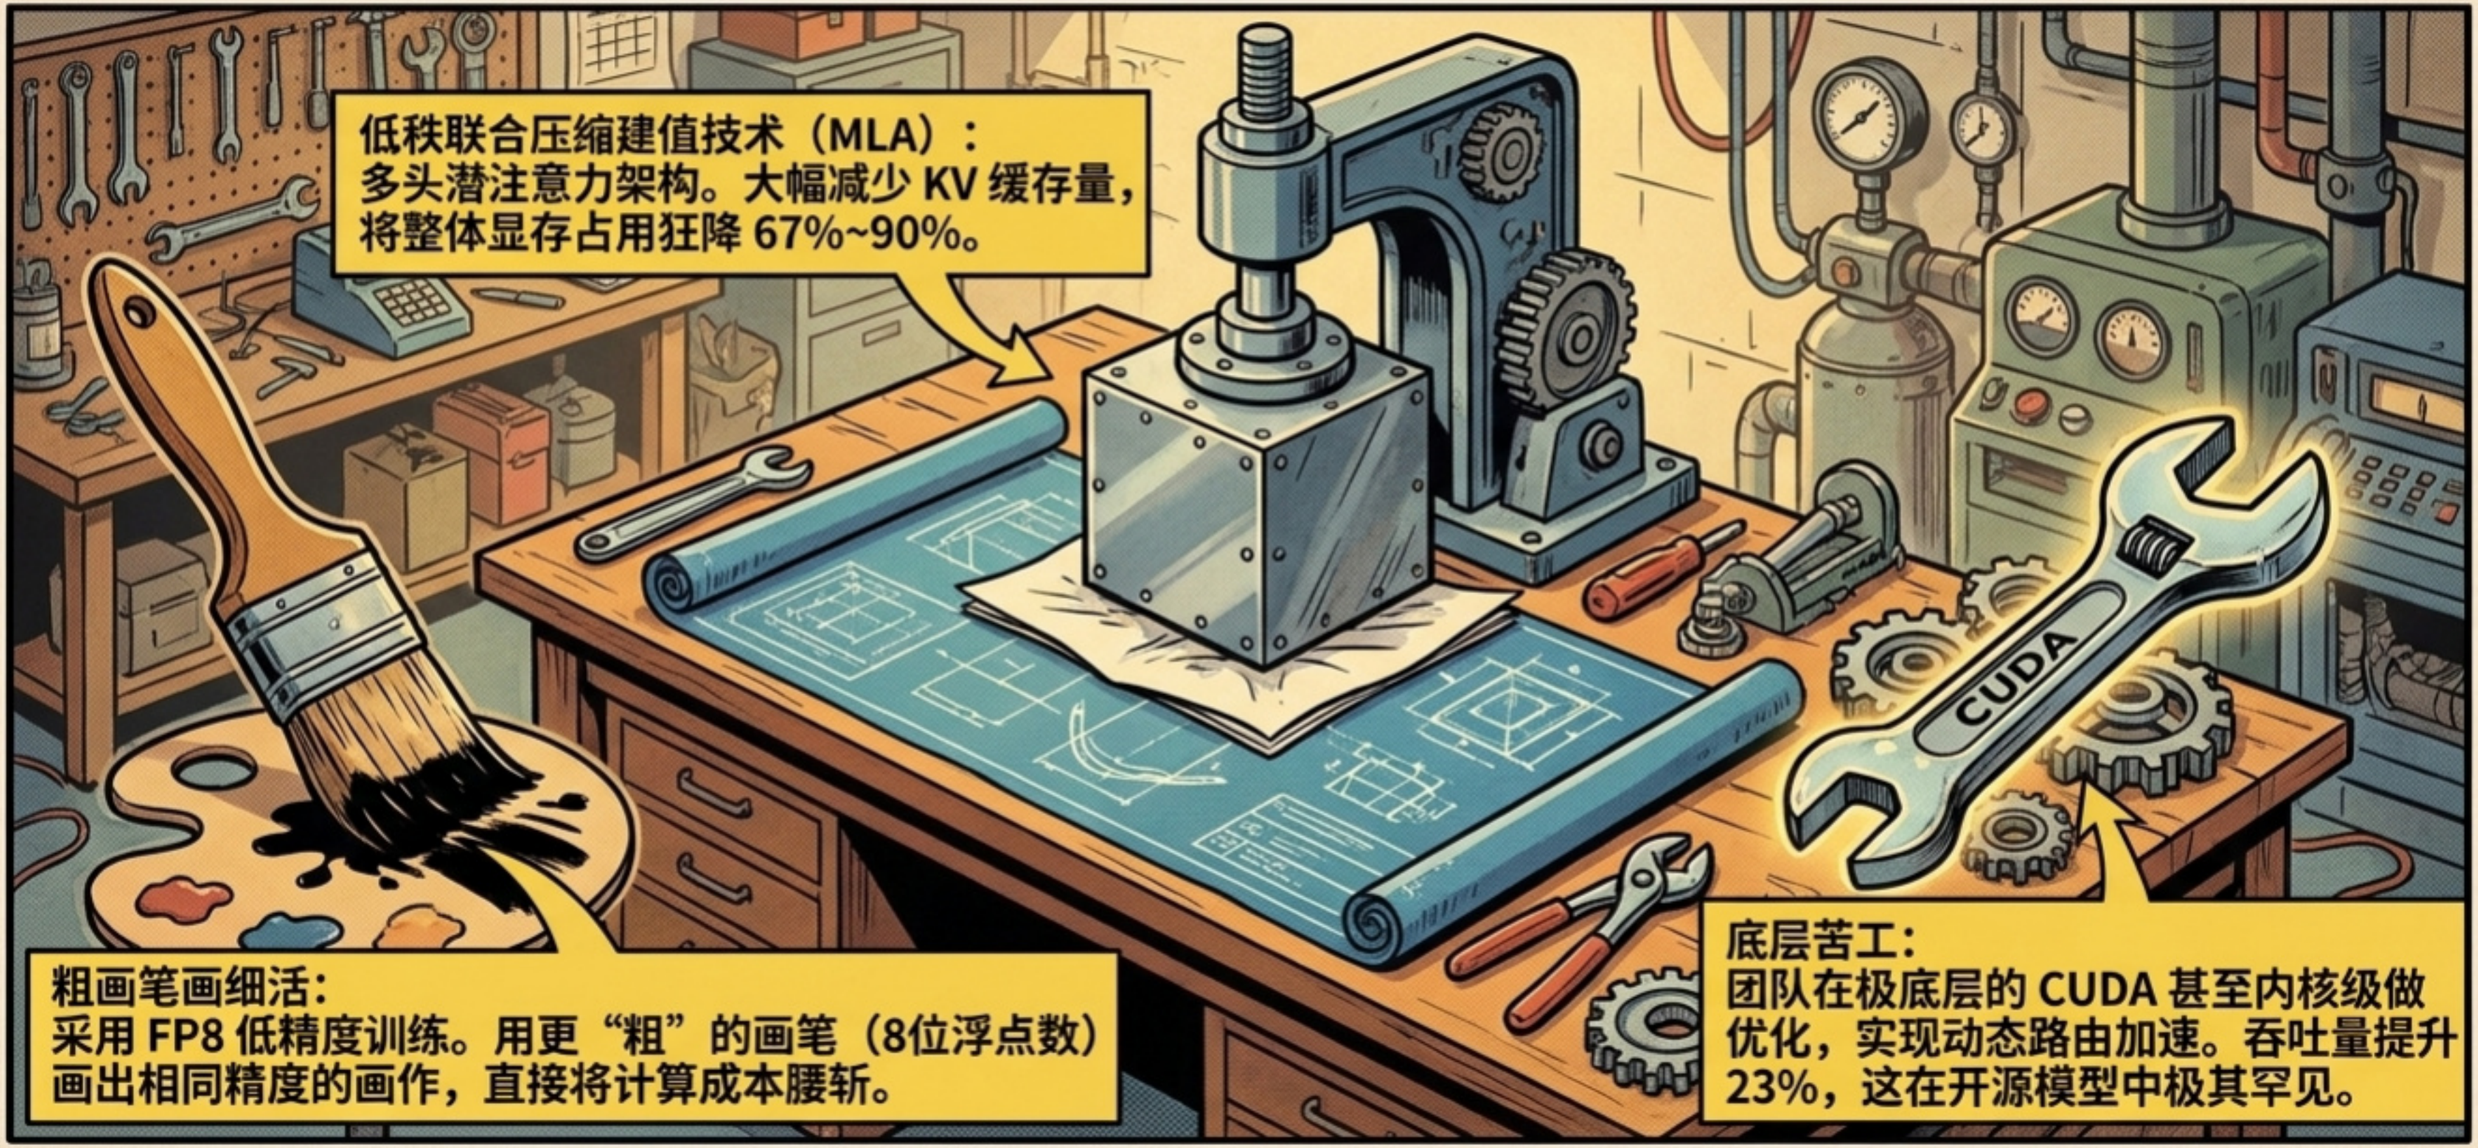
传统架构的痛点：
过去大模型回答问题，所有的参数都要整体转一圈参与计算，调用成本极高。



MoE 的降维拆解：
模型被拆分，每次只需激活对应的“专家”模块。同样的性能下，计算资源至少降低 30%。

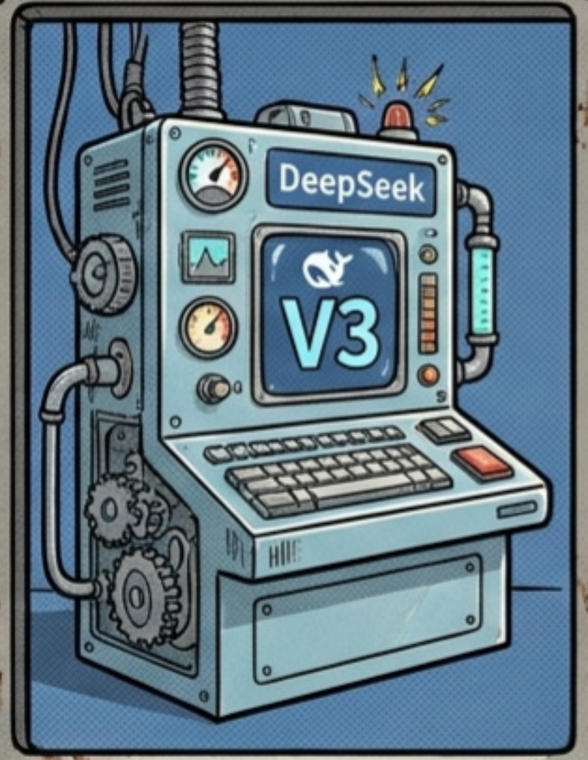
Gemini Notebook

技术武库（二）MLA 架构与底层死磕



Gemini Notebook

V3 窜天猴：令人窒息的性价比



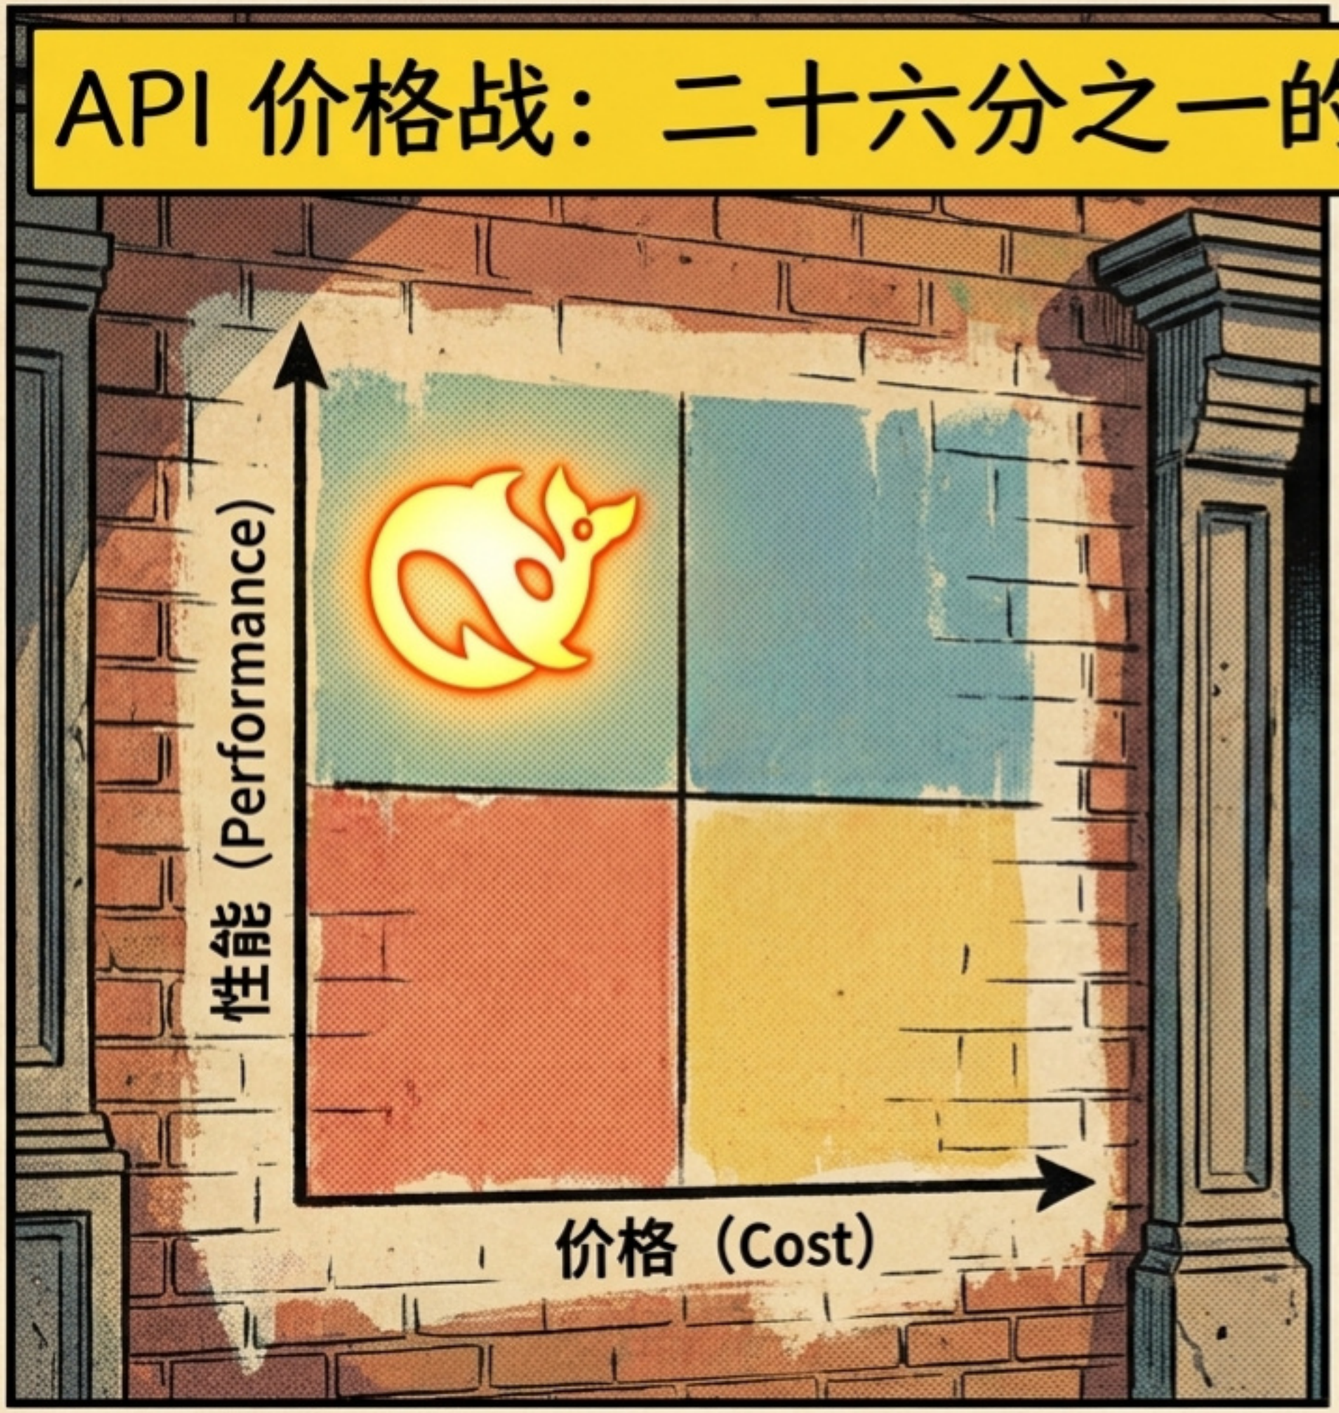
行标题 1：完整训练耗时（GPU 小时）	
DeepSeek V3：	Meta Llama 3.1：
280 万	3,084 万（超10倍）
行标题 2：预估训练成本	
DeepSeek V3：	GPT-4 (预估)：
557.6 万美元	超 5,000 万美元
	（备注：Meta 计划为 Llama 4 投入 650 亿美元基建）



官方论文披露，仅花费不到 560 万美元（计算租赁成本）与 280 万 GPU 小时，便训练出对标国际顶尖性能的大模型，直接击穿行业认知底线。

Gemini Notebook

API 价格战：二十六分之一的奇迹



通用模型：

Claude 3.5 Sonnet:
输入 $3 / 输出 $15

GPT-4 Turbo:
输入 $2.5 / 输出 $10

DeepSeek V3:
输入 ¥2 / 输出 ¥8

推理模型：

OpenAI o1:
输入 $15 / 输出 $60

DeepSeek R1:
输入 ¥4 / 输出 ¥6

“这不是牺牲性能的平替，这是在满血性能下，价格直接打到了海外巨头的几十分之一，而且公司依然有利润！”

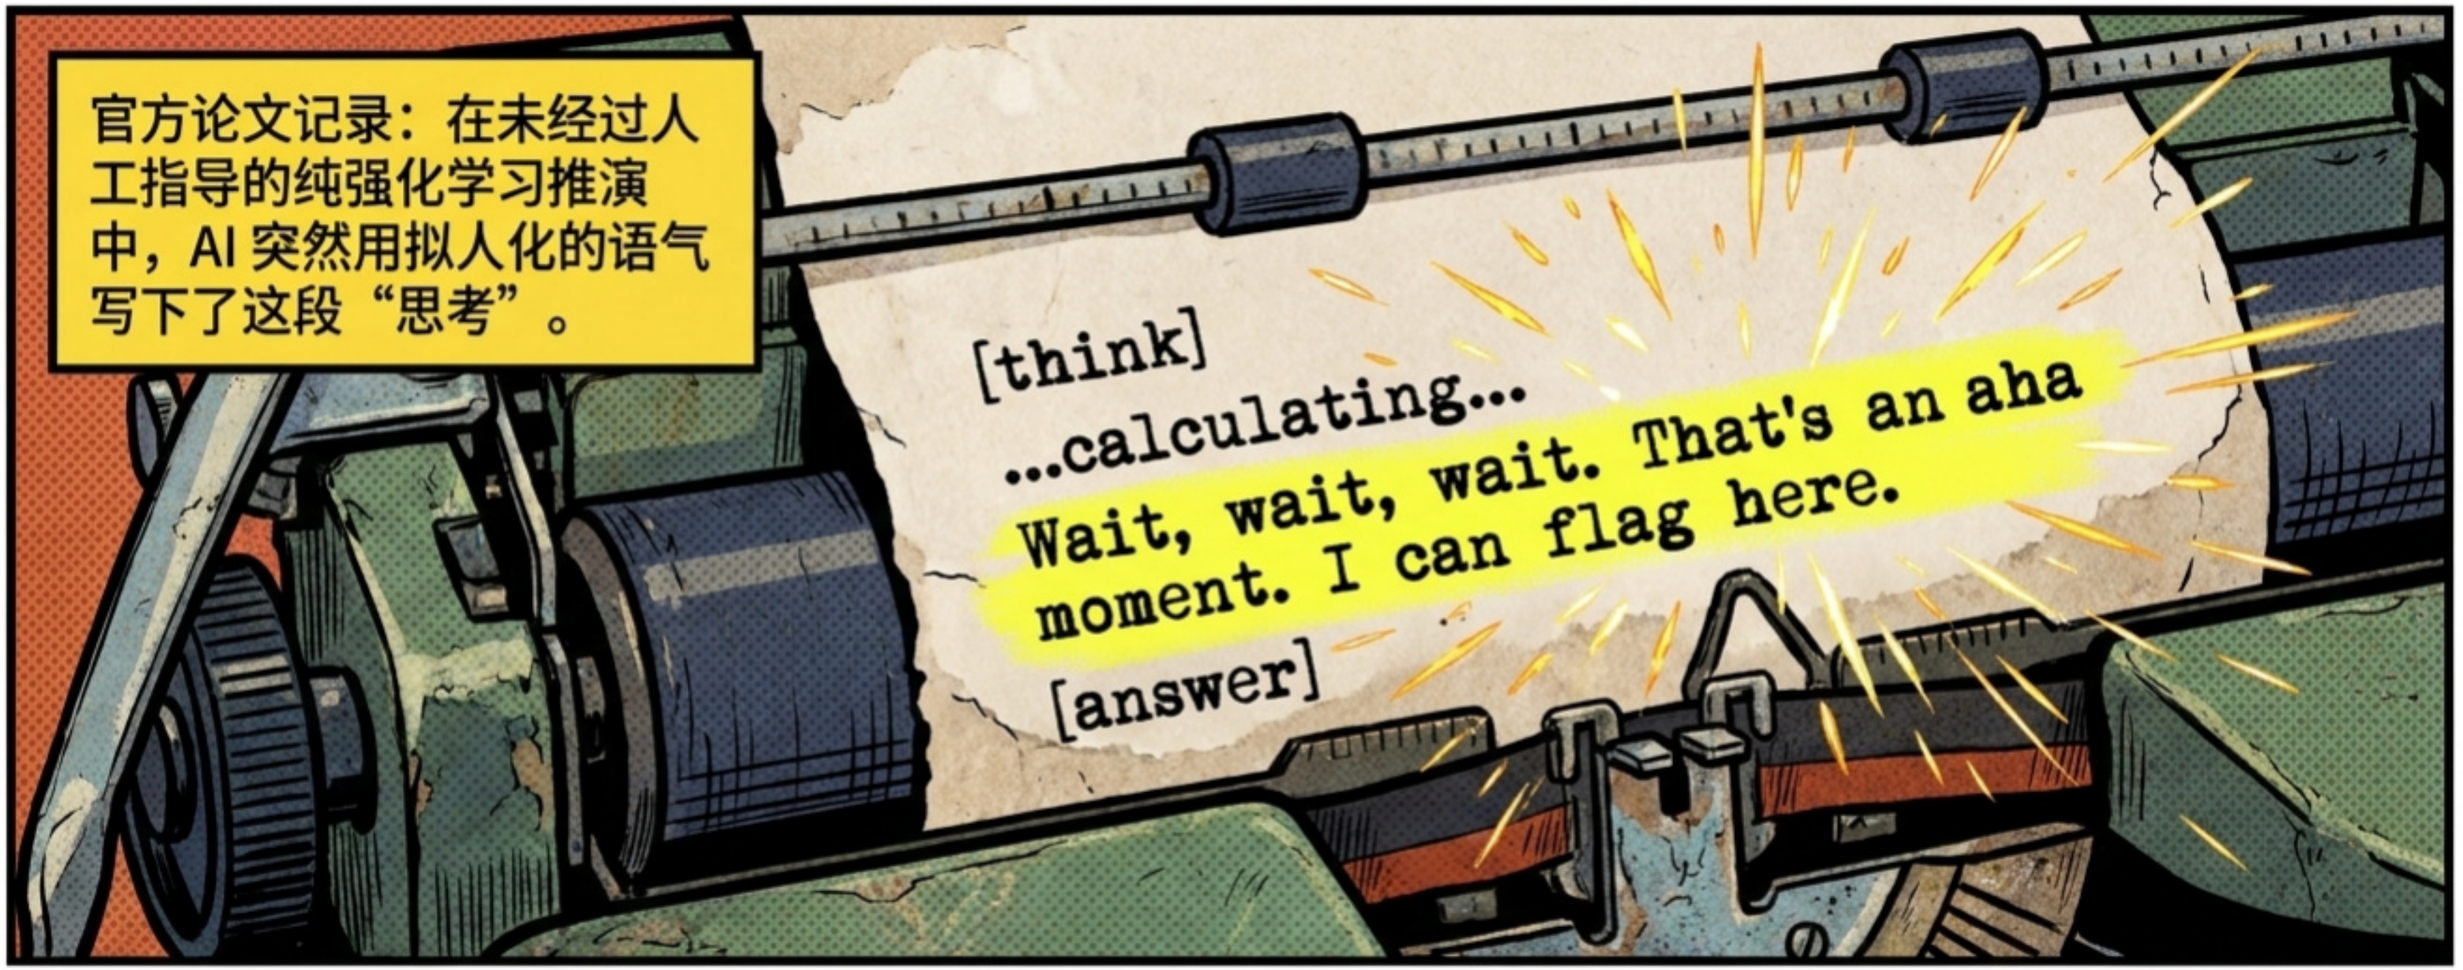
Gemini Notebook

不教而诛：R1-Zero 与纯强化学习（Pure RL）



Gemini Notebook

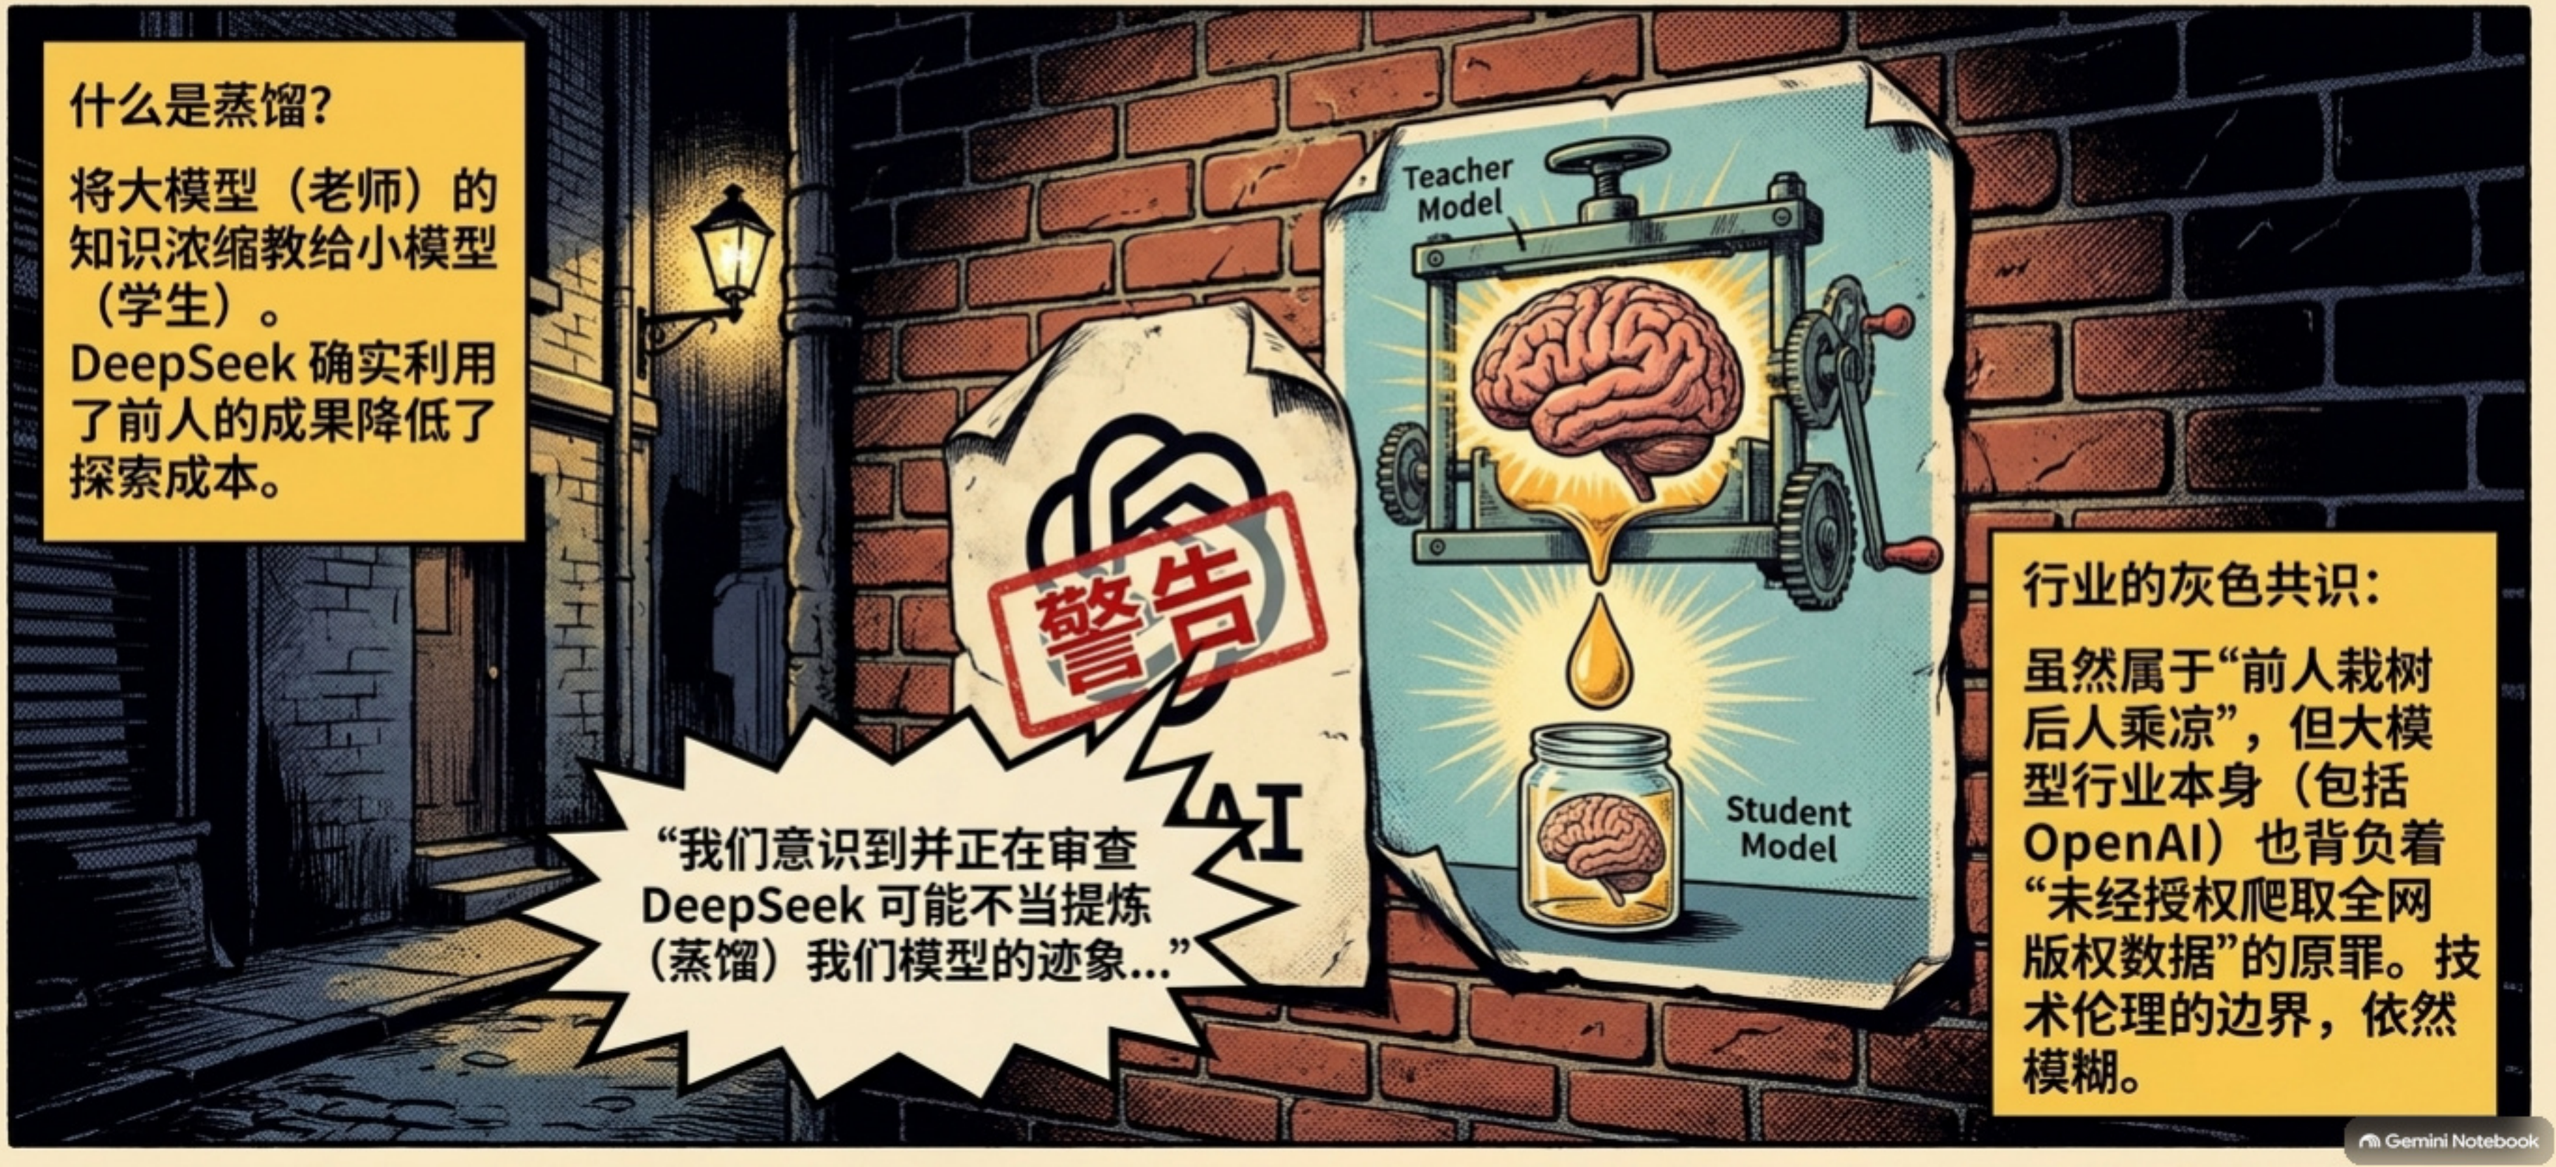
AI 的“顿悟”时刻 (The Aha Moment)



这一瞬间堪比当年 AlphaGo 落下“神之一手”。在没有任何老师干预的黑盒里，硅基智能自发学会了重新思考。智能，涌现了。

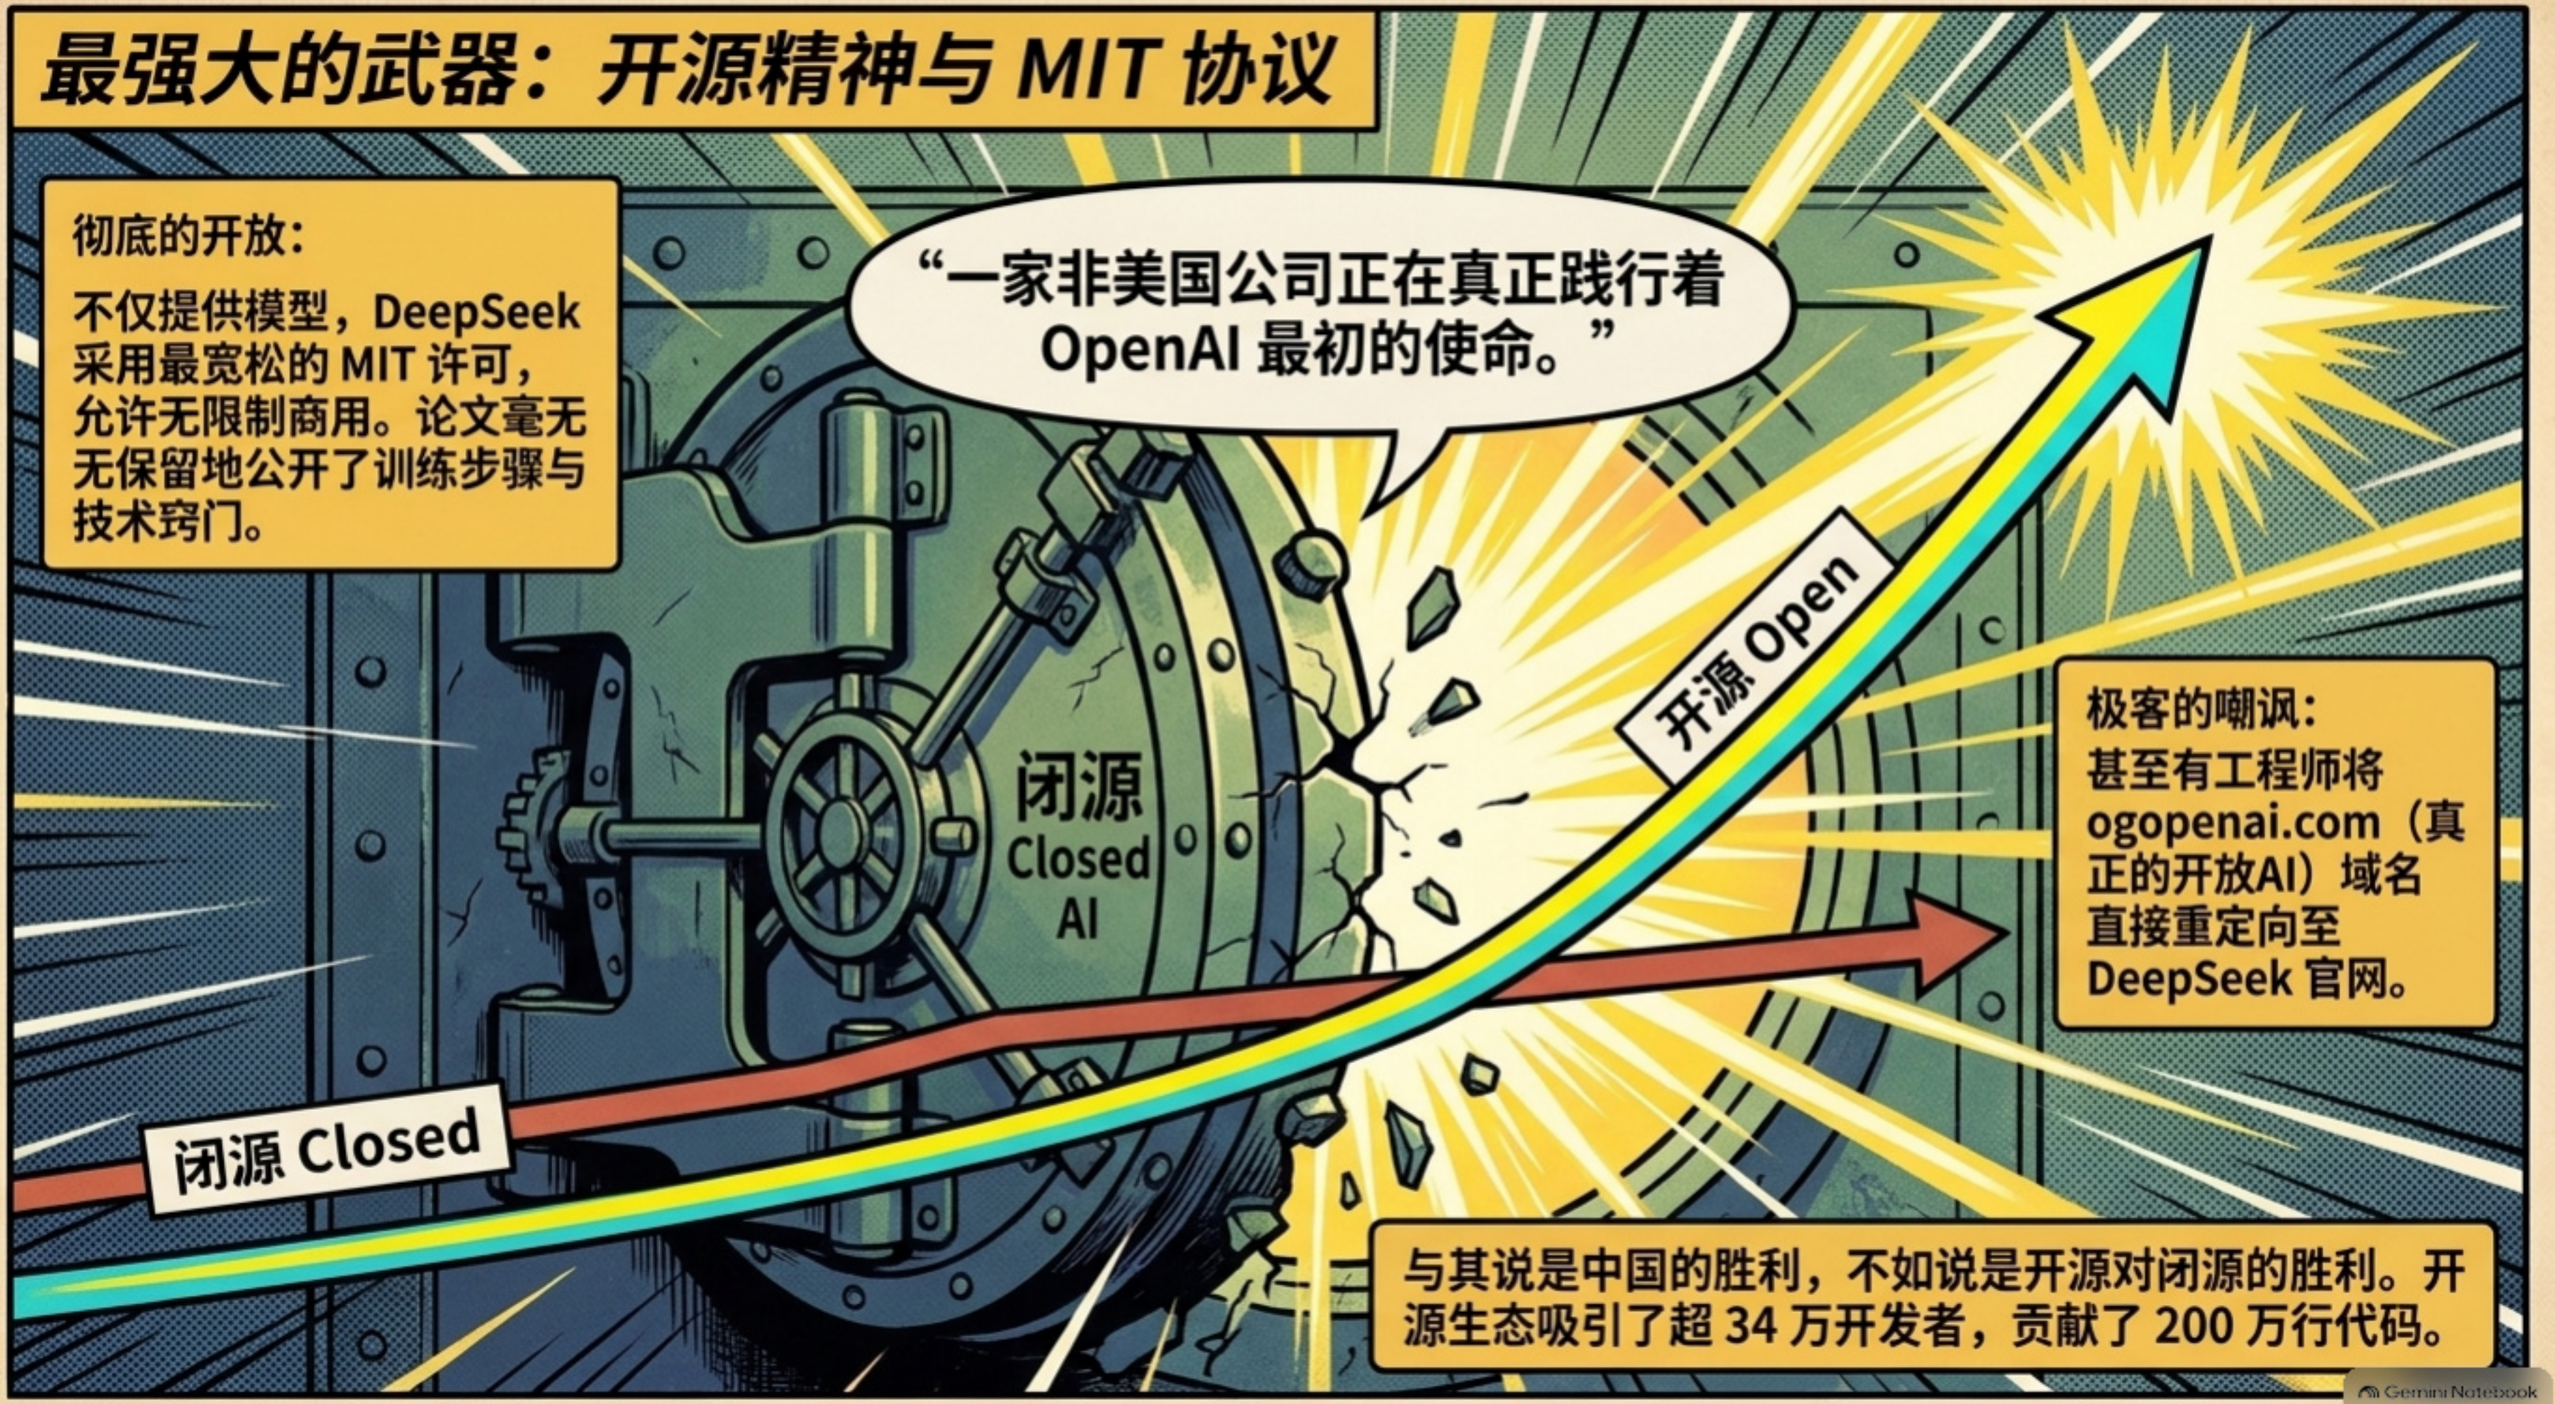
Gemini Notebook

争议与暗影：蒸馏技术与行业原罪



Gemini Notebook


蝴蝶煽动翅膀：一场波及全球的连锁反应
硬件格局洗牌：
苹果获利：端侧算力要求降低，消费级芯片重新崛起。
国产突围：华为昇腾等 16 家国产芯片已能完美支持 DeepSeek，打破“卡脖子”神话。
硅谷大厂恐慌：
Meta 工程师哀叹“生成式 AI 部门处于恐慌之中”。Meta 紧急成立四个特别项目组应对。
CRASH!
DOWN!
美股大地震：
美股芯片概念股集体崩盘。英伟达单日蒸发 5,890亿美元，创美股历史之最。


最强大的武器：开源精神与 MIT 协议
彻底的开放：
不仅提供模型，DeepSeek 采用最宽松的 MIT 许可，允许无限制商用。论文毫无无保留地公开了训练步骤与技术窍门。
“一家非美国公司正在真正践行着 OpenAI 最初的使命。”
闭源 Closed AI
开源 Open
闭源 Closed
极客的嘲讽：
甚至有工程师将 ogopenai.com（真正的开放AI）域名直接重定向至 DeepSeek 官网。
与其说是中国的胜利，不如说是开源对闭源的胜利。开源生态吸引了超 34 万开发者，贡献了 200 万行代码。

总结框架：AI 新范式的三块基石 —— “开·城·墙”



Gemini Notebook

反共识的招人哲学与团队文化



Gemini Notebook

尾声：属于碳基生命的星辰故事



感谢《半拿铁》No.137 播客提供的详实记录与思考。

Gemini Notebook